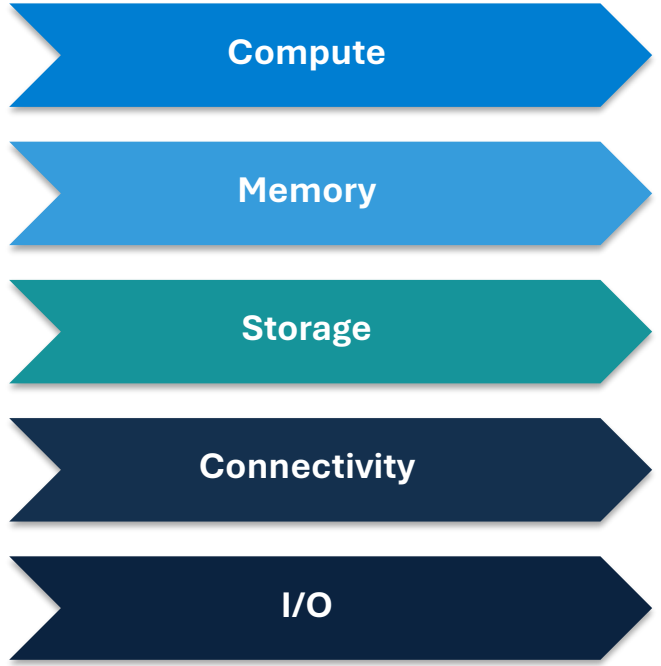
Lekcija 4

HARDVER

Od procesora i memorijske hijerarhije
do
SoC-a, akceleratora i hardverske sigurnosti



Jasmin Azemović

Univerzitetski profesor | Microsoft Security MVP

2

Osnove hardvera

Od fizičkih komponenti do zajedničkog računarskog sistema.

Šta je hardver?

Hardver je fizički sloj IT sistema — ali vrijednost nastaje tek kada komponente rade kao cjelina.

Procesiranje

CPU, GPU, NPU i drugi akceleratori izvršavaju instrukcije i obrađuju podatke.

Memorija

Registri, cache i RAM drže podatke dovoljno blizu procesoru.

Pohrana

SSD, HDD i drugi mediji trajno čuvaju podatke i rezultate.

Povezivanje

Interconnect, mreža i I/O povezuju komponente, uređaje i korisnike.

Energija

Napajanje i hlađenje određuju održive performanse i pouzdanost.

Ključna ideja

Performanse nisu osobina jedne komponente. One nastaju iz odnosa compute, memory, storage, connectivity i I/O slojeva.

Od vakumske cijevi do mikroprocesora

Najvažniji trend: više funkcija u sve manjem, pouzdanijem i energetski efikasnijem sklopu.

1940-e

Vakumske cijevi

Velike, tople, energetski zahtjevne

1950-e

Tranzistori

Manji, pouzdaniji, efikasniji

1960-e

Integrisana kola

Mnogo tranzistora na jednom čipu

1970-e →

Mikroprocesor

CPU funkcije integrisane u jedan čip

Danas

SoC / chiplets

CPU + GPU + NPU + I/O + sigurnost

Miniaturizacija nije sama sebi cilj: omogućava veću integraciju, manju potrošnju i nove oblike uređaja.

Kako računar predstavlja podatke?

Od bita do Unicodea: hardver obrađuje bitove, a softver im daje značenje.

5 Bit i byte

Bit = 0 ili 1
Byte = 8 bita
Osnova digitalnog predstavljanja podataka.

5 Decimalne jedinice

kB, MB, GB, TB
1 kB = 1000 B
Koriste SI bazu 10.

2^n Binarne jedinice

KiB, MiB, GiB, TiB
1 KiB = 1024 B
Koriste bazu 2.

U+ Unicode i UTF

Unicode definiše kodne tačke. UTF-8, UTF-16 i UTF-32 su načini kodiranja.

Primjer

Tekst „č“ nije samo jedan byte u svakom encodingu. Značenje znaka i njegova fizička reprezentacija nisu ista stvar.

Osnovna arhitektura računarskog sistema

Compute, memory, storage, connectivity i I/O čine međuzavisnu cjelinu.

Compute
Procesiranje podataka



- CPU – generalno procesiranje
- GPU – paralelno procesiranje
- NPU – AI zadaci
- Više jezgri i niti
- SoC (System-on-Chip)

Memory
Brz i privremen pristup



- Registri
- Cache memorija (L1, L2, L3)
- RAM (npr. DDR5)
- Visoka brzina, manji kapacitet
- Određuje koliko brzo CPU može obraditi podatke

Storage
Dugoročna pohrana



- SSD (SATA, NVMe)
- HDD
- Flash memorija
- Optički mediji
- Trake (arhivska pohrana)
- Cloud storage (kao usluga)

Connectivity
Povezivanje komponenti



- Matična ploča i chipset
- PCI Express
- USB
- Mrežni interfejsi
- Sabirnice i interkonekti
- Povezivanje internih i eksternih komponenti

I/O
Ulaz i izlaz podataka



- Ulazni uređaji (tastatura, miš, kamera, mikrofon, senzori, ...)
- Izlazni uređaji (monitori, štampači, audio, haptika, ...)
- Kombinovani uređaji (touchscreen, AR/VR, ...)

Podaci (informacije) → **Obrada (procesi)** → **Pohrana (rezultati)** → **Prenos (komunikacija)** → **Korisnik** (usluga, aplikacija)

Performanse i pouzdanost računarskog sistema ne određuje jedna komponenta, već način na koji sve komponente zajedno rade.

7

Procesiranje

CPU ostaje centralni opći procesor, ali više nije jedini compute resurs.

Procesor — CPU

CPU izvršava instrukcije i koordinira opšti tok izvršavanja sistema.

→ Control unit

Dohvata i dekodira instrukcije; usmjerava njihovo izvršavanje.

+ ALU / execution

Izvodi aritmetičke, logičke i druge operacije nad podacima.

R Registri

Najbrža memorija u jezgri za trenutno korištene vrijednosti.

C Cache

Smanjuje čekanje CPU-a na sporiju glavnu memoriju.

CPU ne “radi sve”.

Savremeni sistem raspoređuje grafičke, AI, media i druge specijalizovane zadatke na GPU, NPU i druge akceleratore.

Jezgre, threadovi i clock

Tri pojma koja se često pogrešno tretiraju kao ista stvar.

Core

Fizička procesorska jezgra može nezavisno izvršavati tok instrukcija. Više jezgri povećava paralelizam.

Thread

Logički tok izvršavanja. SMT može omogućiti da jedna jezgra obrađuje više threadova.

GHz Clock

Frekvencija takta izražava broj ciklusa u sekundi. GHz nije direktna mjera ukupnih performansi.

Multicore + efikasna paralelizacija

→ veći throughput za workload koji se može podijeliti

KLJUČNI
KONCEPT

Viši GHz ≠ automatski brži procesor.

Performanse zavise od arhitekture, IPC-a, broja jezgri, cachea, memorije, power limita, hlađenja i — najvažnije — konkretnog workload-a.

Savremene procesorske arhitekture

Arhitektura instrukcijskog skupa (ISA) nije isto što i proizvođač procesora.

x86 **x86-64**

Dominantna ISA u klasičnim PC i mnogim serverskim sistemima. Širok softverski ekosistem.

ARM **Arm**

RISC arhitektura prisutna od mikrokontrolera i smartphonea do laptopa i data centara.

R-V **RISC-V**

Otvorena i modularna ISA. Raste u embedded, edukacijskim i specijalizovanim sistemima.

ISA definiše “jezik” koji procesor razumije; mikroarhitektura određuje kako ga konkretni čip izvršava.

Izvori: Arm Architecture; RISC-V International

Heterogeno računarstvo: CPU, GPU i NPU

Različite arhitekture imaju različite snage — savremeni sistem pokušava workload poslati na najefikasniji resurs.

Heterogeno računarstvo: CPU, GPU i NPU

Različite arhitekture, zajednički cilj – veća efikasnost kroz specijalizaciju i integraciju u jednom čipu.

SoC (System-on-Chip)

Integracija CPU, GPU i NPU u jednom čipu

CPU

Central Processing Unit



Opće namijenska procesorska jedinica koja izvršava širok spektar zadataka i upravlja radom sistema.

- Generalna obrada i kontrola
- Fleksibilnost
- Operativni sistem i aplikacijska logika
- Sekvencijalni i opći zadaci

GPU

Graphics Processing Unit



Visoko paralelna procesorska jedinica optimizovana za obradu velikog broja podataka.

- Masovni paralelizam
- Grafika i rendering
- Matrice i vektorski proračuni
- Naučni i AI workload-i

NPU

Neural Processing Unit



Specijalizovana procesorska jedinica za ubrzanje AI operacija, posebno neuronskih mreža.

- Specijalizovana AI obrada
- Visoka efikasnost za inferencing
- Obrada glasa, slike i AI funkcija
- Niska potrošnja energije

CPU	GPU	NPU
kontrola i fleksibilnost	paralelizam	AI efikasnost

Savremeni sistemi sve češće kombinuju CPU, GPU i NPU kako bi svaki workload izvršavali na najefikasnijem resursu.

System-on-Chip (SoC)

Integracija više funkcija u jednom čipu ili paketu smanjuje udaljenosti između komponenti i poboljšava energetsku efikasnost.

CPU

Opći zadaci

GPU

Grafika i paralelizam

NPU

AI inferencing

Memory controller

Pristup memoriji

I/O & media

USB, display, codec

Security

Secure enclave / roots of trust

Prednost: integracija, manja potrošnja, manji fizički prostor. Kompromis: manja modularnost i teža nadogradnja pojedinačnih komponenti.

14

Memorija i pohrana

Brzina, kapacitet i cijena po bitu stvaraju memorijsku hijerarhiju.

Hijerarhija memorije

Što je memorija bliže procesoru, obično je brža, manja i skuplja po bitu.



Cache, RAM i memory hierarchy

CPU koristi više nivoa memorije kako bi što rjeđe čekao podatke.

Registri

Najbrže, najmanje

Unutar jezgre

L1 / L2

Vrlo brzo

Po jezgri ili blizu jezgre

L3

Veći shared cache

Dijeljen među jezgrama

RAM

Veliki radni skup

Privremena glavna memorija

SSD

Trajna pohrana

Mnogo sporije od RAM-a

Zašto cache postoji?

Jer procesor može izvršavati instrukcije brže nego što RAM i storage mogu kontinuirano dostavljati podatke.

RAM: kapacitet nije jedina karakteristika

Savremena glavna memorija mora balansirati kapacitet, bandwidth, latency, potrošnju i fizički format.

DRAM

Najčešća tehnologija glavne radne memorije. Volatile: gubi sadržaj bez napajanja.

DDR

Generacije DDR memorije povećavaju efektivnu propusnost i mijenjaju električke karakteristike.

↔ Bandwidth

Koliko podataka memorijski sistem može prenijeti u jedinici vremena.

⏱ Latency

Koliko se čeka od zahtjeva do dostupnosti podatka. Nije isto što i bandwidth.

Specijalizovana memorija

VRAM i HBM koriste se kada GPU/akceleratori trebaju vrlo veliku propusnost memorije.

Trajna pohrana: HDD, SATA SSD i NVMe

Storage je mnogo sporiji od RAM-a, ali nudi trajnost i znatno veći kapacitet.

HDD HDD

Magnetni medij sa mehaničkim dijelovima. Veliki kapacitet i niska cijena po GB, ali viši latency.

SSD SATA SSD

Flash memorija bez pokretnih dijelova. Znatno niži latency od HDD-a, ali ograničena SATA interfejsom.

NVMe NVMe SSD

NVMe protokol je dizajniran za nevolatilnu memoriju i koristi prednosti PCIe interconnecta.

Cloud storage nije fizički medij.

To je usluga koja se u pozadini oslanja na fizičke storage sisteme i mrežnu infrastrukturu.

HDD vs. SATA SSD vs. NVMe SSD

Ne postoji “najbolji storage” bez konteksta: kriteriji se razlikuju po workloadu.

Tehnologija	Latency	Throughput	Cijena/kapacitet	Tipična uloga
HDD	visok	niži	najniža	arhiva, veliki kapacitet
SATA SSD	nizak	srednji	srednja	opći klijentski workload
NVMe SSD	vrlo nizak	visok	viša	aktivni workload, server, workstation

Važno: stvarne performanse zavise od workload-a — sekvencijalni throughput i random I/O nisu ista metrika.

20

Povezivanje i I/O

Brza komponenta ne pomaže ako podaci do nje ne mogu stići dovoljno brzo.

Matična ploča i interconnect

Komponente računara moraju razmjenjivati podatke kroz standardizovane interfejse i sabirnice.

PCIe **PCI Express**

Visokopropusni interconnect za GPU, NVMe, mrežne kartice i druge uređaje.

RAM **Memory channels**

Povezuju CPU i RAM. Broj kanala i brzina memorije utiču na ukupni bandwidth.

USB **USB / Thunderbolt**

Eksterni I/O za periferije, storage, display i druge uređaje.

NIC **Network I/O**

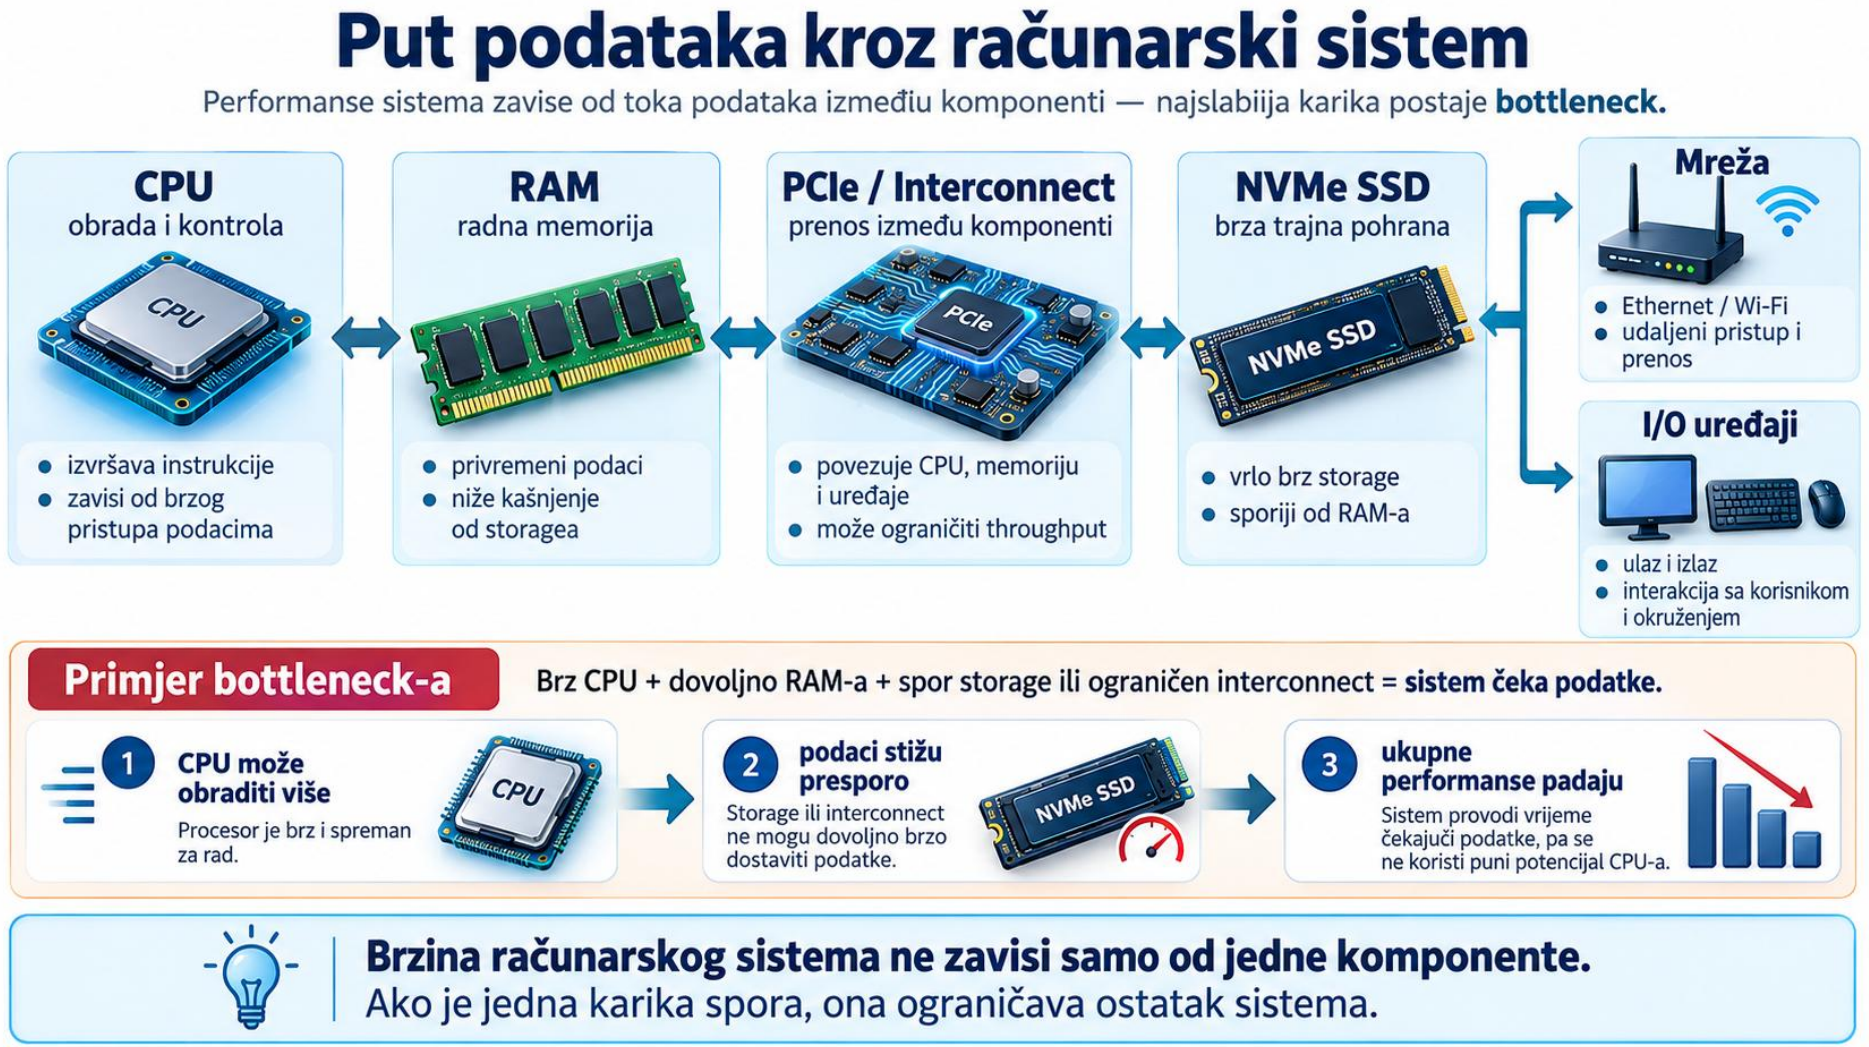
Ethernet i Wi-Fi povezuju sistem sa udaljenim resursima i servisima.

Bottleneck

Najuže grlo može biti CPU, memorija, interconnect, storage, mreža ili čak hlađenje — zavisno od workload-a.

Put podataka i bottleneck

Najslabija karika može ograničiti ostatak sistema, bez obzira koliko je CPU brz.



Ulazni i izlazni uređaji

I/O povezuje digitalni sistem sa korisnikom i fizičkim okruženjem.

IN Ulaz

Tastatura, miš, kamera, mikrofon, skener, senzori, čitači i drugi izvori podataka.

OUT Izlaz

Monitori, projektori, štampači, audio uređaji, haptika i drugi oblici predstavljanja rezultata.

I/O Kombinovani uređaji

Touchscreen, AR/VR headset i drugi uređaji koji istovremeno primaju i prikazuju podatke.

Savremeni I/O nije samo “periferija”.

U automobilu, IoT uređaju ili industrijskom sistemu senzori i aktuatori mogu biti ključni dio računarske funkcije.

Senzori, RFID i biometrija

Fizički svijet postaje podatak kada uređaj može izmjeriti, identificirati ili prepoznati događaj.

Senzori

Temperatura, pritisak, ubrzanje, svjetlo, lokacija, kamera i drugi izvori mjerenja.

RFID / NFC

Identifikacija i komunikacija na kratkim udaljenostima bez klasičnog fizičkog kontakta.

Biometrija

Otisak prsta, lice, iris i glas koriste fiziološke ili ponašajne karakteristike osobe.

Sigurnosna napomena

Biometrijski podatak nije password koji se može jednostavno promijeniti. Njegovo prikupljanje i zaštita zahtijevaju poseban tretman.

Mrežni hardver

U ovoj lekciji mrežu posmatramo sa hardverske strane — kako se uređaj fizički i logički povezuje.

NIC **NIC**

Mrežni adapter povezuje računar na Ethernet ili drugi mrežni interfejs.

SW **Switch**

Povezuje uređaje unutar lokalne mreže i prosljeđuje frameove prema odredištu.

RT **Router**

Povezuje različite mreže i usmjerava pakete prema drugim mrežnim segmentima.

Wi-Fi **Access point**

Omogućava bežičnim uređajima pristup mreži putem Wi-Fi veze.

Ethernet i Wi-Fi nisu “internet”.

To su tehnologije pristupa i povezivanja; internet je mreža mreža i skup protokola/usluga iznad njih.

26

Energija, sigurnost i trendovi

Održive performanse zavise od snage, temperature, arhitekture i povjerenja u hardver.

Napajanje, hlađenje i thermal throttling

Procesor koji se pregrijava ne može beskonačno održavati maksimalne performanse.

Power

CPU, GPU i drugi elementi imaju power budget. Više snage može omogućiti više performansi — do fizičkih granica.

Cooling

Air i liquid cooling uklanjaju toplotu. Data centri optimizuju i hlađenje cijele infrastrukture.

Thermal throttling

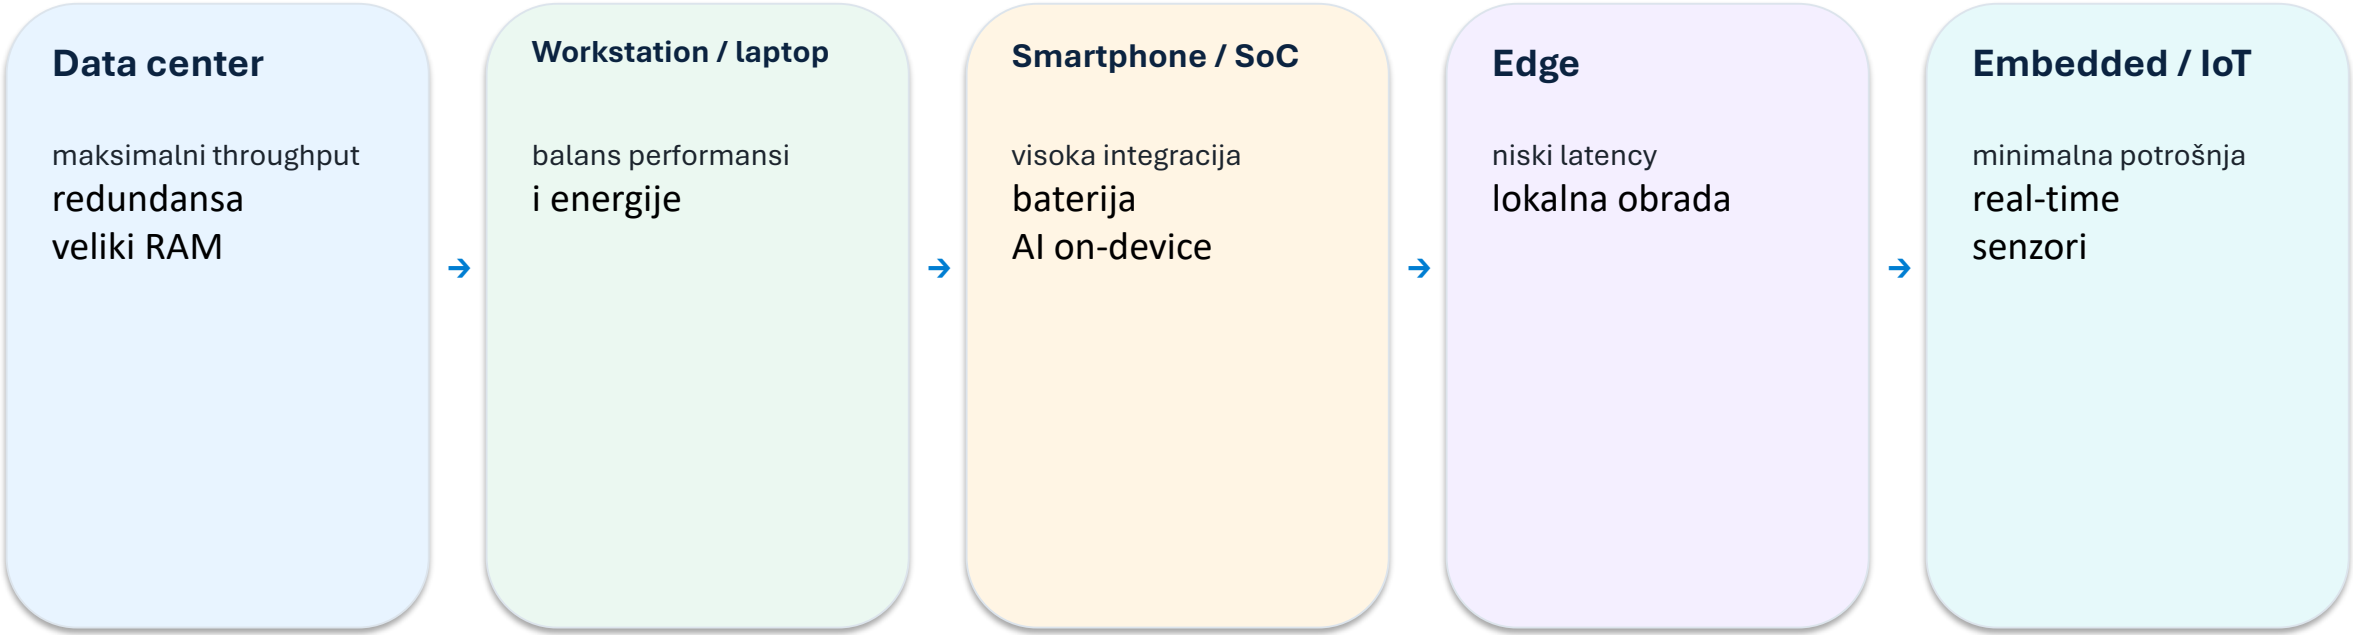
Kada temperatura ili power limit dostignu granicu, sistem smanjuje frekvenciju ili napon.

Sustained performance ≠ peak performance

Za laptop, server ili AI akcelerator često je važnije koliko performansi može održavati kroz vrijeme nego kratkotrajni maksimum.

Od data centra do edge uređaja

Isti osnovni principi hardvera pojavljuju se u potpuno različitim fizičkim i energetskim okvirima.



Ne klasificiramo hardver samo prema veličini — workload, energija, pouzdanost, cijena, real-time zahtjevi i fizički prostor često su važniji.

Savremeni trendovi u hardveru

Razvoj više ne zavisi samo od povećanja frekvencije jednog CPU jezgra.

Chiplets

više funkcionalnih čipleta u jednom packageu

3D packaging

vertikalna integracija i kraći interconnect

AI akceleratori

GPU, NPU i workload-specifični procesori

HBM

veliki memory bandwidth za akceleratore

RISC-V

otvorena ISA i modularni dizajn

Quantum

specijalizovan model za odabrane klase problema

Hardver i sigurnost

Sigurnost sistema počinje prije operativnog sistema.

FW Firmware

Inicijalizira hardver. Kompromitovan firmware može zaobići kontrole viših slojeva.

✓ Secure Boot

Provjerava povjerenje u komponente boot lanca prije pokretanja operativnog sistema.

TPM TPM

Root of trust za ključeve, mjerenja integriteta i attestation.

🔒 Fizička zaštita

Portovi, krađa uređaja, supply chain i neovlaštene modifikacije ostaju važan rizik.

Hardware-backed security ne zamjenjuje sigurnost OS-a i aplikacija — ona im daje čvršću osnovu povjerenja.

Izvor: Trusted Computing Group — TPM 2.0

Hardver od data centra do edge uređaja

Isti osnovni principi računarskog sistema pojavljuju se u različitim fizičkim oblicima i uz različite prioritete.

1 Data centar / server



maksimalne performanse i skalabilnost

2 Workstation / laptop



ravnoteža performansi i fleksibilnosti

3 Smartphone / SoC



mobilnost i visoka integracija

4 Edge uređaj



niska latencija i lokalna obrada

5 Embedded / IoT



minimalna potrošnja i specifična funkcija

Zaključak: Kako se krećemo od data centra prema edge i IoT uređajima, obično se smanjuju resursi i potrošnja energije, a rastu specijalizacija, mobilnost i blizina korisniku ili senzoru.

Ključne poruke

Hardver je sistem, ne lista komponenti.

Compute, memory, storage, I/O i connectivity moraju raditi zajedno.

GHz nije isto što i performanse.

Arhitektura, jezgre, cache, memorija, energija i workload mijenjaju rezultat.

CPU više nije jedini compute resurs.

GPU, NPU i drugi akceleratori omogućavaju heterogeno računarstvo.

Memory hierarchy smanjuje čekanje na podatke.

Što je memorija bliže CPU-u, tipično je brža, manja i skuplja po bitu.

Performanse imaju fizičke granice.

Interconnect, storage, mreža, napajanje i hlađenje mogu postati bottleneck.

Sigurnost počinje u hardveru.

Firmware, Secure Boot, TPM i fizička zaštita grade osnovu povjerenja.

Pitanja / diskusija

Za provjeru razumijevanja i povezivanje koncepata.

1. **Zašto laptop sa nižim GHz može biti brži od modela sa višim GHz?**
2. **Koji workload biste poslali na CPU, koji na GPU, a koji na NPU?**
3. **Zašto RAM ne može zamijeniti SSD i obrnuto?**
4. **Kako biste prepoznali da je storage bottleneck?**
5. **Zašto je thermal throttling važan za realne performanse?**
6. **Kako TPM i Secure Boot doprinose povjerenju u sistem?**

Diskusija: Koju komponentu biste prvo nadogradili na vlastitom računaru — i zašto?